#### Selayang Pandang

#### Model Linear

Ali Akbar Septiandri

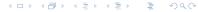
Universitas Al-Azhar Indonesia aliakbars@live.com

April 1, 2020

1 Ulasan

2 Regresi Linear

Simple Linear Regression Basis Function Regression Regularisation



BAHAN BACAAN

1 VanderPlas, J. (2016). Python Data Science Handbook.

(In Depth: Linear Regression)

http://nbviewer.jupyter.org/github/jakevdp/ PythonDataScienceHandbook/blob/master/notebooks/ 05.06-Linear-Regression.ipynb

- 2 Murray, I. (2016). MLPR class notes. (Linear Regression) http://www.inf.ed.ac.uk/teaching/courses/mlpr/2016/notes/ (graduate level)
- 3 Septiandri, A.A. (2019). Artificial Intelligence Kuliah 2: Regresi Linear. Github.



#### ULASAN

### Minggu Lalu...

- Dimensionality Reduction
- Eigenvector & Eigenvalue
- Principal Component Analysis

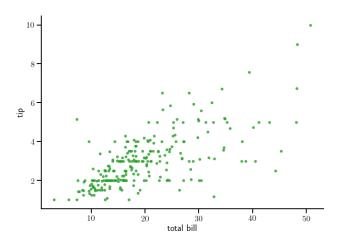
Apa interpretasi dari determinan? Apa hubungannya dengan nilai eigen?

**◆□▶ ◆□▶ ◆■▶ ■ り**९@

Video dari Victor Lavrenko untuk PCA

REGRESI LINEAR

# Prediksi hubungan antara dua Variabel



GAMBAR: Data hubungan antara total harga pesanan dan tip yang diberikan



#### SIMPLE LINEAR REGRESSION

#### FUNGSI LINEAR

Kasus paling sederhana adalah mencocokkan garis lurus ke sekumpulan data

$$y = ax + b$$

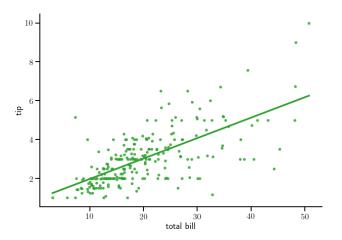
dengan a adalah slope, sedangkan b dikenal dengan nama intercept.

#### Notasi lain

$$y = w_0 + w_1 x_1$$

dengan w adalah bobot atau koefisien.

# Prediksi hubungan antara dua Variabel



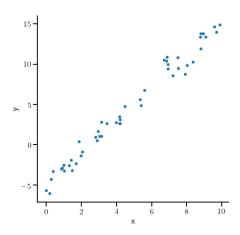
GAMBAR: Data hubungan antara total harga pesanan dan tip yang diberikan



#### SIMPLE LINEAR REGRESSION

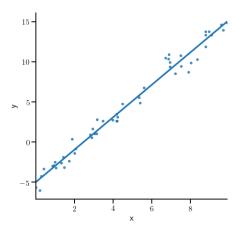
#### EXAMPLE

rng = np.random.RandomState(1)
x = 10 \* rng.rand(50)
y = 2 \* x - 5 + rng.randn(50)
plt.scatter(x, y);



GAMBAR: Data yang dimunculkan secara acak [VanderPlas, 2016]

#### MENCOCOKKAN GARIS



Gambar: Hasil pencocokan garis [VanderPlas, 2016]

Model slope: 2.02720881036

Model intercept: -4.99857708555



# MULTIDIMENSIONAL LINEAR REGRESSION

Model

$$y = w_0 x_0 + w_1 x_1 + w_2 x_2 + \dots + w_D x_D = \sum_{j=0}^{D} w_j x_j$$

dengan  $x_0 = 1$ 

Notasi matriks-vektor

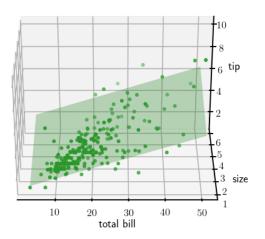
$$y = \phi \mathbf{w}$$

dengan  $\phi = (1, \mathbf{x}^T)$ 

Bagaimana kalau ada lebih dari dua variabel yang ingin kita lihat hubungannya?



# REGRESI LINEAR UNTUK DUA VARIABEL



GAMBAR: Hubungan antara total bill dan jumlah tempat duduk (size) terhadap jumlah tip



# PREDIKTOR LINEAR (CONTOH)

#### Vektor bobot $\mathbf{w} \in \mathbb{R}^D$

bias: 0.67

total bill: 0.09

size: 0.19

## Vektor fitur $\phi(x) \in \mathbb{R}^D$

bias: 1

total bill: \$12.02

size: 2

$$\hat{y} = \mathbf{w} \cdot \phi(x)$$

$$= \sum_{j=1}^{D} w_j \phi_j(x)$$

$$= 0.67(1) + 0.09(12.02) + 0.19(2) = 2.13$$

Jadi, diprediksi bahwa untuk pelanggan dengan  $total\ bill=\$12.02\ \mathrm{dan}\ size=2,\ \mathrm{pramusajinya}\ \mathrm{akan}$  mendapatkan  $\approx\$2.13.$ 

4□ > 4□ > 4□ > 4□ > 4□ > 4□ > 9

Kita sudah tahu nilai y dan  $\phi$ , tapi berapa nilai  $\mathbf{w}$ ?



Nyatanya, kita tidak bisa mencari nila<br/>i $\phi^{-1}$ 

 $\phi$  bukan matriks bujur sangkar dan datanya mengandung noise

#### Asumsi Gaussian Noise

- Asumsikan  $y = \mathbf{w}^T \boldsymbol{\phi} + \epsilon \text{ dengan } \epsilon \sim \mathcal{N}(0, \sigma_{\epsilon}^2)$
- Berdasarkan asumsi distribusi Gaussian, implikasinya  $p(y|\boldsymbol{\phi}, \mathbf{w}) = \mathcal{N}(y; \mathbf{w}^T \boldsymbol{\phi}, \sigma_{\epsilon}^2)$
- Dengan asumsi i.i.d., nilai log likelihood menjadi

$$L(\mathbf{w}) = \sum_{i=1}^{N} \log p(y|\boldsymbol{\phi}, \mathbf{w})$$
$$= -\frac{N}{2} \log(2\pi\sigma_{\epsilon}^{2}) - \frac{1}{2\sigma_{\epsilon}^{2}} \sum_{i=1}^{N} (y_{i} - \mathbf{w}^{T} \boldsymbol{\phi}_{i})^{2}$$



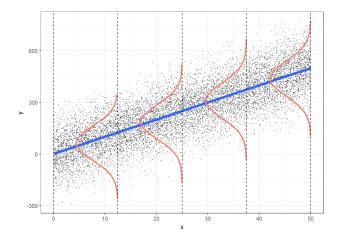
#### MEMINIMALKAN ERROR

$$L(\mathbf{w}) = -\frac{N}{2}\log(2\pi\sigma_{\epsilon}^2) - \frac{1}{2\sigma_{\epsilon}^2} \sum_{i=1}^{N} (y_i - \mathbf{w}^T \boldsymbol{\phi}_i)^2$$
$$= -C_2 - C_1 \sum_{i=1}^{N} (y_i - \mathbf{w}^T \boldsymbol{\phi}_i)^2$$

dengan  $C_1 > 0$  dan  $C_2$  tidak terpengaruh oleh **w**. Beberapa hal yang perlu diketahui:

- Mengalikan dengan konstanta positif tidak akan mengubah titik maksimum
- Menambahkan konstanta tidak mengubah titik maksimum
- $\sum_{i=1}^{N} (y_i \mathbf{w}^T \boldsymbol{\phi}_i)^2$  adalah sum of squared errors

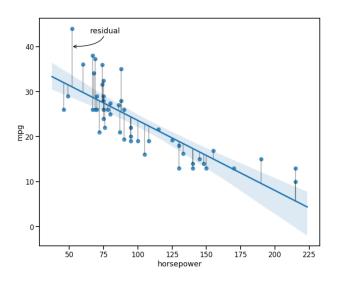
# Fungsi Linear dengan Gaussian Noise



GAMBAR: Fungsi linear dengan Gaussian noise dalam asumsi ordinary least squares



Jadi, memaksimalkan *likelihood* akan sama dengan meminimalkan *sum of squared error*.



Gambar: Meminimalkan sum of squared errors



#### Solusi

- Jawaban: Minimalkan  $E(\mathbf{w}) = \sum_{i=1}^{n} (y_i \mathbf{w}^T \mathbf{x}_i)^2$  dengan mencari turunan parsial yang diatur sama dengan 0
- Solusi analitis:

$$\hat{\mathbf{w}} = (\boldsymbol{\phi}^T \boldsymbol{\phi})^{-1} \boldsymbol{\phi}^T \mathbf{y}$$

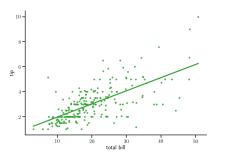
- Bagian  $(\pmb{\phi}^T \pmb{\phi})^{-1} \pmb{\phi}^T$ dikenal sebagai pseudo-inverse

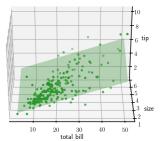
- Harus menggunakan loss function  $E(\mathbf{w})$  yang dapat diminimalkan
- Pilihan umum: squared error

$$E(\mathbf{w}) = \sum_{i=1}^{n} (y_i - \mathbf{w}^T \mathbf{x}_i)^2$$
$$= (\mathbf{y} - \phi \mathbf{w})^T (\mathbf{y} - \phi \mathbf{w})$$



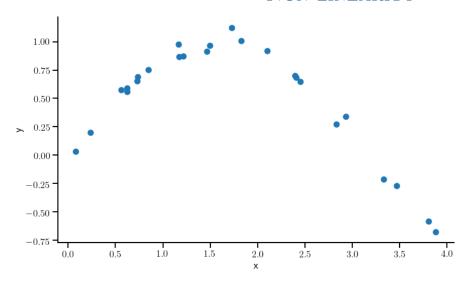
#### PERHATIKAN KEMBALI





Apa kekurangan dari regresi linear sederhana seperti ini?

#### Non-Linearity



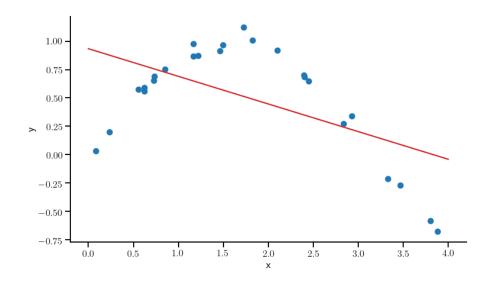
Gambar: Data yang dihasilkan dari fungsi sin dengan noise

Bagaimana kalau datanya seperti ini?



Jika model yang dihasilkan lebih sederhana dibandingkan data yang seharusnya dicocokkan, maka model tersebut disebut mengalami underfitting.

#### Underfitting



Gambar: Hasil fitting regresi linear sederhana



#### POLYNOMIAL BASIS FUNCTIONS

REGRESI LINEAR DENGAN FUNGSI BASIS POLINOMIAL Jika kita mengubah  $x_p = f_p(x)$ , dengan  $f_p()$  adalah fungsi transformasi, maka untuk  $f_p() = x^p$  dan x adalah input berdimensi satu, modelnya menjadi

$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

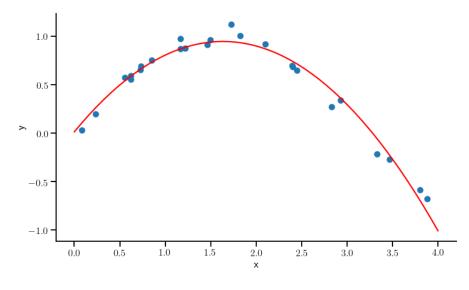
#### IN

```
from sklearn.preprocessing import PolynomialFeatures
x = np.array([2, 3, 4])
poly = PolynomialFeatures(3, include_bias=False)
poly.fit_transform(x[:, None])
```

#### OUT



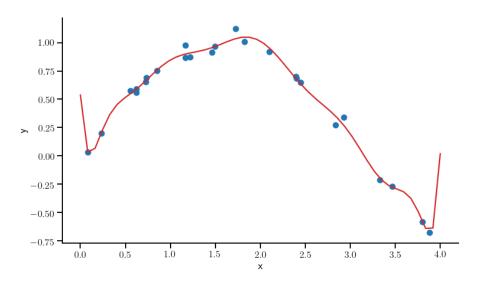
Apa yang terjadi jika p dibuat lebih besar?



Gambar: Hasil fitting fungsi basis polinomial p = 2



#### **OVERFITTING**



Gambar: Hasil fitting fungsi basis polinomial p = 12

Jika model yang dihasilkan lebih kompleks (~ parameternya banyak) dibandingkan data yang seharusnya dicocokkan, maka model tersebut disebut mengalami overfitting.

Kita dapat menggunkan fungsi basis Gaussian sebagai alternatif (non-examinable)





#### RIDGE REGRESSION

Bagaimana cara menghindari overfitting?

- Digunakan untuk menghindari overfitting
- Dikenal juga sebagai  $L_2$  regularisation atau Tikhonov regularisation
- Pemberian penalti untuk koefisien model

$$P = \alpha \sum_{j=1}^{p} w_j^2 = \alpha \|\mathbf{w}\|_2^2$$

# Loss Function pada Ridge Regression

• Loss function yang harus diminimalkan menjadi

$$E(\mathbf{w}) = \sum_{i=1}^{n} (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \alpha \|\mathbf{w}\|_2^2$$

dengan  $\|\mathbf{w}\|_d = (\sum_{j=1}^p |w_j|^d)^{\frac{1}{d}}$ 



# Loss Function pada Ridge Regression

• Loss function yang harus diminimalkan menjadi

$$E(\mathbf{w}) = \sum_{i=1}^{n} (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \alpha \|\mathbf{w}\|_2^2$$

dengan  $\|\mathbf{w}\|_d = (\sum_{j=1}^p |w_j|^d)^{\frac{1}{d}}$ 

- Parameter  $\alpha$  (terkadang juga ditulis sebagai  $\lambda$ ) bernilai bebas (ditentukan oleh pengguna)
- Solusi analitis:

$$\hat{\mathbf{w}} = (\boldsymbol{\phi}^T \boldsymbol{\phi} + \alpha I_p)^{-1} \boldsymbol{\phi}^T \mathbf{y}$$

# Loss Function pada Ridge Regression

• Loss function yang harus diminimalkan menjadi

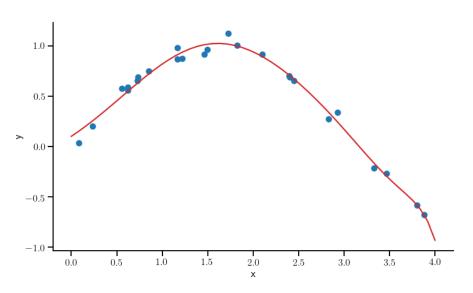
$$E(\mathbf{w}) = \sum_{i=1}^{n} (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \alpha \|\mathbf{w}\|_2^2$$

dengan  $\|\mathbf{w}\|_d = (\sum_{j=1}^p |w_j|^d)^{\frac{1}{d}}$ 

• Parameter  $\alpha$  (terkadang juga ditulis sebagai  $\lambda$ ) bernilai bebas (ditentukan oleh pengguna)



#### RIDGE REGRESSION

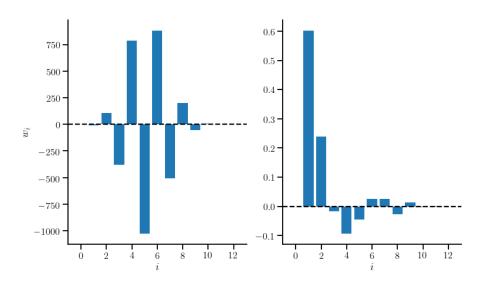


Gambar: Fitting fungsi basis polinomial p=12 dengan Ridge  $\alpha=0.1$ 





#### PERUBAHAN KOEFISIEN



GAMBAR: Dengan ridge regression, koefisien diubah menjadi kecil



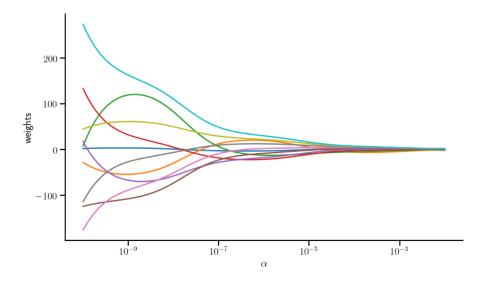
# LASSO REGRESSION

- Secara konsep mirip seperti ridge regression
- Penalti dengan jumlah nilai absolut dari koefisien (1-norms;  $L_1$  regularisation)

$$P = \alpha \sum_{j=1}^{p} |w_j|$$

• Bekerja dengan membuat banyak koefisien bernilai nol

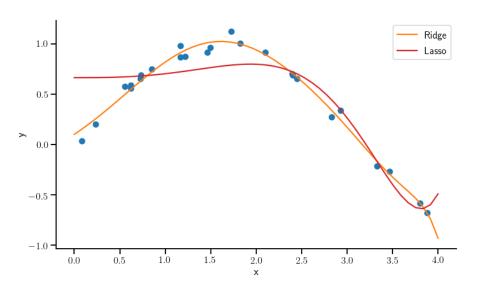
#### Perubahan w terhadap $\alpha$



Gambar: Semakin besar  $\alpha$ , w semakin kecil (sumber: scikit-learn)



#### RIDGE VS LASSO REGRESSION

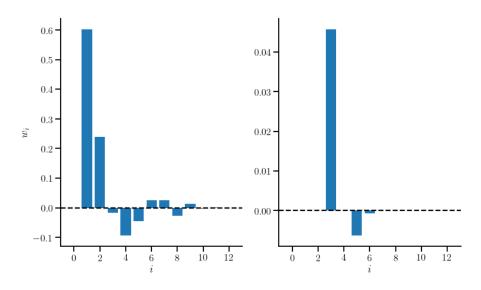


Gambar: Perbandingan Ridge dan Lasso dengan  $\alpha=0.1$ 



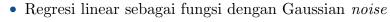
#### PERUBAHAN KOEFISIEN

#### IKHTISAR



GAMBAR: Perbandingan Ridge dan Lasso

Referensi



- Asumsi Gaussian noise  $\rightarrow$  sum of squared error
- Ordinary least squares (OLS) didapatkan dengan solusi analitis dari fungsi error
- Transformasi fitur dan regularisasi

Terima kasih

Jake VanderPlas (2016)
In Depth: Linear Regression
Python Data Science Handbook